

智能语音V2.6部署指南

系统及软件要求

系统优化项

参数优化

禁用防火墙和SELinux

端口范围

Docker运行时根目录

架构

概要图

服务清单

部署

配置项

授权服务

语音服务

模型准备

初始化

启动服务

自验证

停止服务

指定服务启动

指定服务停止

访问调用

集群

健康检查

负载均衡

维护

异常排查

系统及软件要求

指标	要求	自检命令
系统版本	CentOS 7.4+ 系列(请勿最小化安装, 否则可能有功能兼容性不完整问题), 其它能支持docker的Linux系统理论上可以运行, 但可能存在不可预期的兼容性问题, 请自行验证	uname
系统时间	CST 时区, 北京时间, 误差在1分钟内	date
CPU	32C+, intel, 支持avx2指令, 主频 2.5GHz+	grep avx2 /proc/cpuinfo
内存	128G, 具体请查阅相应服务资源要求, asr 或 tts 基础服务至少需要64G+, 具体需参考对应模型要求	free -g
磁盘	500G+	df -h
Docker	1.12.x + 或 17.06.0+	docker -v

注意：请部署实施前检查相关项是否满足要求，如上基准配置，更多详情请参阅《部署架构与资源标准》。

友情提示：

1：Docker 通过yum在线安装会相对简单

docker官方安装指导：<https://docs.docker.com/install/linux/docker-ce/centos/#install-docker-ce>

2：Docker 离线安装请自己通过备份对应rpm安装。

3：2.x架构均使用标准docker镜像交付，请自行了解所有docker相关技术和使用

系统优化项

注意：如下优化是必选项

参数优化

1. 文件描述符和进程数(线程数)等优化

文件路径： /etc/security/limits.conf

```
*          - nproc           65535
*          - sigpending     65535
*          - nofile          655350
```

文件路径： /etc/security/limits.d/20-nproc.conf 可能会为 例如90-nproc.conf，以实际为准

```
*               - nproc               65535
```

禁用防火墙和SELinux

```
systemctl stop firewalld.service      #停止firewall
systemctl disable firewalld.service   #禁止firewall开机启动
```

如果/etc/selinux/config中SELINUX=enforcing，需做如下修改并重启系统

修改/etc/selinux/config 文件
将SELINUX=enforcing 改为 SELINUX=disabled
重启系统生效

端口范围

修改临时分配端口范围

```
# 查看本机临时端口
sysctl net.ipv4.ip_local_port_range

# 修改到10000+起始，避免占用服务监听端口
sudo sysctl -w net.ipv4.ip_local_port_range="10000 64000"
```

Docker运行时根目录

注意: 由于docker的限制，如果在部署后再调整需要清理docker镜像和容器等后再重新配置并重启，建议在首次部署即考虑该项。

1. docker对磁盘的占用较大，请预先设置docker root dir为大磁盘路径，并重启查看是否生效

v17.05.0 以下版本配置方法

文件路径： /etc/docker.conf 或者 /etc/sysconfig/docker 请根据当前docker版本自行判断

```
--graph=/new/path/to/docker-data
```

```
# Modify these options if you want to change the way the docker daemon runs
OPTIONS='--selinux-enabled --log-driver=journald --signature-verification=false --graph=/home/admin/docker'
if [ -z "${DOCKER_CERT_PATH}" ]; then
    DOCKER_CERT_PATH=/etc/docker
fi
```

v17.05.0 以上版本配置方法

修改 /etc/docker/daemon.json ,如果不存在则创建一个


```
{
  "data-root": "/new/path/to/docker-data"
}
```

架构

专有云V2启用全新架构，全新变化：

- 全系容器化，可运行在物理机，swarm，k8s等多种体系内，真正实现WORA(Write once, run anywhere)
- 全新交互协议，更健壮
- 自主研发的基础服务能力开放，如网格寻址，负载均衡等能力
- 自主管控运维监控能力开放
- 服务与模型松耦合
- 语音算法全系升级
- 定制化服务全面开放

概要图



服务清单

- 所有应用除管控设施外均以简要名代表，实际名会有nls或nls-cloud前缀，以下服务是按需提供。
- 详情请参考 《智能语音V2.X部署架构与资源标准》

部署

注意：

将提供的安装包放置到您需要部署运行的位置，推荐放置到 /home/admin 目录下，后续沟通均默认以此目录为基准。请保证该目录磁盘可用空间满足资源标准。

配置项

当前所有的开放配置项都在 service/conf/nls.conf 里，里面有所有中间件，apes等连接相关的配置，您可以按需修改。如果是单实例，您无需做任何配置，直接下一步吧。

授权服务

重要：

- Apes 必须预先部署和授权激活后才可以进行其他相关部署。
- Apes 提交序列号后未授权前不允许重启Apes本身，否则序列号将变更，对应授权码将失效。
- Apes 会限制运行实例 和 并发控制等。
- Apes 更新授权同新申请步骤一致。
- 该步骤只需在未授权前需要单独启动，授权通过后不再需要单独启动授权服务，其可以随着 start.sh 启动。
- Apes容器化集群部署，请参考 conf/nls.conf 下的 apes_addrs 配置项说明，即配置为实际3个ip地址，逗号分隔，然后在3个ip机器上启动容器即可，集群组网为一次性组网，如果从单机更换为集群，则配置好ip，删除data/apes 下数据重新配置启动即可，请注意如果改变组网，授权会失效。
- 更多信息 请参考 《Apes部署指南》

```
chmod +x ./bin/*
```

```
# 单独提前启动授权服务
```

```
./bin/apes.sh start
```

```
# 获取序列号，请将序列号信息发送给商务同学进行授权，更新授权同如下步骤一致，集群选同一台机器操作即可
```

```
./bin/apes.sh get
```

```
# 根据商务同学提供的授权码进行激活， 注意 未激活前请勿重启apes或者关机重启等操作，否则序列号将变化
./bin/apes.sh put 您的授权码

# 查看授权信息
./bin/apes.sh ctx

# 注销授权（反激活）
./bin/apes.sh reset

# 启动有异常后，进行异常修复，修复完成后再重启
./bin/apes.sh repair
```

语音服务

拷贝对应软件包到对应服务器，请选择放置到磁盘空间较大的路径下。

- 以下命令请以root权限 或者 sudo 超级权限执行
- 请保证端口不被占用，目前使用的为 80 443 3306 6379 7000-9000 27017

模型准备

安装包内一般内置默认模型,路径如下，其它模型类似存放在对应目录下：

类别	相对目录
ASR模型目录	service/resource/asr/default
TTS模型目录	service/resource/tts/default

- 注意： TTS服务内部已经带有一份基础模型，可以实际运行，如需升级或替换模型，才需考虑该步骤。
- 注意： 更新完模型需要重启服务

关于模型更新：备份该default目录，将新模型目录命名为default

```
cd service/resource/asr
mv default 你的备份目录/asr_20181101_bak
mv 新模型目录 default

# 重启服务
./bin/stop.sh
./bin/start.sh
```

以下操作默认在安装包内的 service 目录

初始化

执行如下命令导入镜像，如后续需要更新升级，同样导入相应镜像即可

```
chmod +x ./bin/*

# 如果有老版本，执行 ./bin/clean.sh 可以清除加载到docker的资源，适合全量升级时使用
./bin/init.sh
```

可以通过 docker images 查看镜像是否被加载。

- 镜像是可以按需加载的，比如只需要部署tts服务，则 ./bin/init.sh tts 其会自动加载tts相关的服务

启动服务

一键启动所有服务，用户可以按需定制启动相应服务

- 注意：docker运行后会对映射目录权限进行修改，请提前查看读写权限

```
./bin/start.sh
```

- 可以通过 docker ps 查看服务运行的状态
- 所有日志 在 bin的上层目录logs下面

重点关注：

- 应用理论上在五分钟内即可启动成功，asr或tts 服务由于需要加载模型，启动所需要的时间 根据模型，并发路数和您的机器配置有直接关系，具体启动详情可以关注日志

服务	重点关注日志
asr	logs/nls-cloud-asr/alizr.log
tts	logs/nls-tts/application.log

- 所有数据被持久化在 data 目录下，包括 mysql，redis等，请勿随意删除

自验证

服务启动后，需要运行自验证程序，来确保服务已经正常。

- 请按需选择，您未部署的功能请无须关注

```
# 查看当前安装服务端口状态是否异常，如出现异常，请排查具体服务的日志
sh ./bin/status.sh

# 基于sdk的demo进行基础功能测试，如出现异常，请排查具体服务的日志
sh ./demo/demo.sh
```

停止服务

一键停止所有服务

```
./bin/stop.sh
```

指定服务启动

如果您需要按需指定服务运行，可以进行如下操作（请在您已经知晓相关架构和流程细节后再自行按需定制操作）

```
./bin/start.sh 服务名1(比如nls-cloud-gateway) 服务名2 等
```

指定服务停止

如果您需要按需指定服务运行，可以进行如下操作（请在您已经知晓相关架构和流程细节后再自行按需定制操作）

```
./bin/stop.sh 服务名1
```

访问调用

目前gateway基于websocket协议和sdk交互，已经直接提供RESTful接口，sdk使用请查阅sdk相关文档

功能	连接地址
一句话识别&实时语音转写&语音合成	ws://gateway所在IP:8101/ws/v1
一句话识别RESTful	http://gateway所在IP:8101/stream/v1/asr
语音合成RESTful	http://gateway所在IP:8101/stream/v1/tts
录音文件识别RESTful	http://gateway所在IP:8101/stream/v1/filetrans

MRCP协议调用ASR&TTS	sip地址： nls-cloud-sdm所在IP, sip端口是7010； 如果使用了sdmproxy负载服务，默认地址是： nls-cloud-sdmproxy所在IP， 端口5070；
-----------------	--

- 鉴权：专有云可忽略此概念，阿里云官网关于此功能的描述对于专有云无效；
appkey：专有云可忽略此概念， [appkey 参数传入固定字符串"default" 即可](#)；
access token：专有云可忽略此概念， [token参数传入固定字符串"default" 即可](#)；

集群

据 智能语音V2.X部署架构与资源标准 文中描述，2.x系列采用了全新的集群方案，即采用单实例横向扩容为集群的模式，部署实施者不再需要过多关注语音服务内部调用关系，部署和扩容效率相对原有方案有极大提升。

简而言之，以语言识别链路举例，即每台机器上部署 gateway-realtime-unifypost-asr 全量服务，此服务配合patron服务，可以实现单机全链路服务的健康检查，以配合负载均衡等设备或软件实现流量切换，仅需gateway作为每台机器的对外接口。

健康检查

2.6.3 及以上版本，自带有全链路的健康检查服务，可以配合nginx，F5 等实现流量切换。
patron服务的接口如下：

模式	地址	解释
gateway对外简单模式	http://gateway所在IP:8101/patron/health	当前链路任一服务异常，则改url将返回5xx，否则返回2xx，body为OK
gateway对外详情模式	http://gateway所在IP:8101/patron/details	当前链路任一服务异常，则改url将返回5xx，否则返回2xx，body为json,返回所有服务的异常信息
patron自身	http://patron所在IP:7101/patron/health 与 http://patron所在IP:7101/patron/details	同上，gateway的/patron/**是转发到patron 地址上

负载均衡

对于通过 sdk 或者 mrpc(sdm) 访问服务的，可以使用内部自研负载均衡技术，相关域名配置请打开 Apes的Web 域名管理操作，具体sdk和sdm配置，请参阅相关文档。

也可自行通过nginx，F5 等对gateway进行负载均衡配置，具体请查阅其官方文档

比如nginx可以参考：https://tengine.taobao.org/document_cn/http_upstream_check_cn.html

维护

- 为了更便捷快速排查和定位问题，客户对于专有云部署的环境需要了解基本的异常定位方法，最基本原则：除了看现象，还要看日志。
- 当前版本所有应用日志都定向到了同一个目录下，启动时有日志所在目录提示，客户可以根据上述概要图分析日志，如若有必要，可以提供打包的日志进行分析。
- 如果存在服务启动等异常，且可能导致故障无法排查恢复时，请卸载所有容器服务，并删除运行时数据或者直接更换目录重新部署

异常排查

1. 请查看硬件配置和系统版本是否达到标准，比如内存，硬盘，cpu，是否centos7.2+等，查看局域网络是否异常，比如存在ip冲突，dns配置不当，路由不当等
2. 查看各个docker 服务是否都启动正常，docker ps多次，看看运行时间是否如期，如果容器服务有异常，会退出并重新启动，可以根据 docker logs 容器id 来查看该容器的stdout日志
3. 查看对应服务进程是否存在 ps -ef | grep 进程关键字，几次，看看进程id是否不变
4. 查看对应服务端口是否存在，telnet 127.0.0.1 对应端口 ,并确保端口未被其他应用占用:sudo netstat -pant | grep 端口
5. 查看对应服务日志，日志按标准存储在 logs/对应服务目录下

access.log	记录该应用核心请求的扼要信息，比如请求参数，延时，返回消息等
application.log	记录该应用的所有日志
error.log	记录该应用的错误信息